

总体思路：把图像条件变成三维空间条件

吸收 Affostruction 的空间条件化生成与稀疏流思想，适配 VGGT + TRELLIS 两阶段重建



从 Affostruction 直接采用

- RGBD 像素反投影并附着到三维 voxel
- 空间条件 token + 3D positional encoding
- Transformer cross-attention 条件注入
- 官方 SS 768×12 Conditional Flow Matching

针对图像重建进行适配


- 不使用文本、CLIP 或 affordance prompt
- 条件改为 VGGT 几何 + DINO 语义 + RGB 纹理
- SLat active voxel 回投所有输入视图
- 多视图证据按可见性与一致性融合

总体控制原则

- SS 决定“哪里存在结构”
- SLat 决定“结构点具有什么属性”
- 观测充分区域由 VGGT 校正
- 证据不足区域回归 TRELLIS 生成先验

02 SS : RGBD 体素条件驱动的官方生成流

将 VGGT 的不确定性几何变成 Affostruction SS Flow 可读取的紧凑三维 token



空间条件构造

$$\mathbf{Xc} = [(u - cx)d/fx, (v - cy)d/fy, d]$$

$$\mathbf{Xw} = \mathbf{Tc2w} \mathbf{Xc} \rightarrow q = \text{floor}[(Xw + 0.5) \cdot 16]$$

- 每个 voxel 先求平均采样位置，再用 grid_sample 读取 DINO
- 仅观测 voxel 进入 condition；view_valid_mask 排除 padding

官方模型拓扑

- SparseStructureFlowModel
- resolution 16^3 ；in/out 8 channel
- hidden 768；12 blocks；12 heads
- absolute PE；Q/K RMS norm
- DINO 冻结；SS Flow 全参数微调

Conditional Flow Matching

$$\mathbf{x}_t = (1 - t)\mathbf{x}_0 + [\sigma_{\min} + (1 - \sigma_{\min})t]\boldsymbol{\varepsilon}$$

$$\mathbf{v}^* = (1 - \sigma_{\min})\boldsymbol{\varepsilon} - \mathbf{x}_0$$

$$\text{LSS} = \|\mathbf{v}\boldsymbol{\theta}(\mathbf{x}_t, t, \mathbf{C}) - \mathbf{v}^*\|^2$$

ODE + CFG → active voxel support


03 SLat：像素对齐、置信度融合与受控残差

把 Affostruction 稀疏条件流转化为冻结 TRELLIS 先验上的图像空间校正器



训练、推理与参数更新闭环

两阶段分开优化，统一坐标与条件契约，在生成完整性和重建约束间分配控制权



SS 参数与目标

- 训练: Affostruction SS Flow 全部参数
- 冻结: DINO 与 RGBD conditioner
- 目标: $L_{SS} = \text{velocity CFM-MSE}$
- CFG dropout 学习有 / 无条件速度场
- EMA 权重用于稳定生成采样

SLat 参数与目标

- 训练: sparse residual flow + conditioner
- 冻结: TRELIS native SLat flow
- Lflow: 最终 velocity 对齐目标速度
- Lendpoint: 反推 clean x0; Lprior: 低可信归零
- Ldecoded: RGB / mask / depth / feature / geometry

统一工程契约

- frame ID 同步
RGB、depth、mask、K、T
- 训练 / 推理统一 canonical frame 与 camera convention
- DDP 多 GPU; BF16 前向; FP32 主权重
- gradient checkpointing 控制激活显存
- 核心原则: 观测校正 + 未观测生成

Pixel → Voxel → Pixel-aligned Evidence → Gated Structured Latent → 3D Asset